EL CUADRE — Plataforma Multi-Inquilino

EL CUADRE — COMO PLATAFORMA QUE ALBERGA VARIOS CLIENTES

Para: Monarca (Key) · Seawolf Studio **De:** Bellion, Gran Comandante **Fecha:** 29 de octubre de 2026 **Encargo (verbatim):** *"se me ocurrió algo, he visto muchos programas que funcionan muy bien albergando varios clientes, quiero explorar ese enfoque a ver si damos con algo bueno."* **Antecedente:** `RADAR-restaurantes-manuales.md` (score 36/40) · vertical = restaurantes que hacen todo a mano y solo usan WhatsApp.

---

0. VEREDICTO EN TRES LÍNEAS

Sí se puede, y es el enfoque correcto — pero cambia la unidad del negocio. No vendemos *una app por restaurante*: vendemos **un lugar dentro de una plataforma**. La arquitectura probada para 50–500 clientes es **base de datos compartida con `tenant_id` + Row Level Security**, con **una sesión de WhatsApp aislada por restaurante** (una sesión = un número). El costo marginal por cliente queda en **US$1–3 de infraestructura + US$0,0008 por respuesta en Colombia**.

Y aparece un dato que el Radar no tenía: en Colombia el canal de WhatsApp de Meta es el más barato de Latinoamérica. Eso baja el riesgo #2 del Radar de *ALTA* a *manejable*.

---

1. QUÉ SIGNIFICA "ALBERGAR VARIOS CLIENTES" — LOS TRES MODELOS, CON NÚMEROS

Existen exactamente tres formas de alojar clientes en un mismo producto. Se eligen por tres criterios: aislamiento que exige el cliente, cuántos clientes se buscan, y capacidad del equipo para operar infraestructura.

Criterio	Base compartida (tenant_id + RLS)	Esquema por inquilino	Base de datos por inquilino
Aislamiento de datos	Lógico, forzado por políticas RLS	Lógico más fuerte	Físico
Sobrecosto de desarrollo	**+15 a 20%**	+20 a 25%	+25 a 30%
Costo de hosting por cliente	**EUR 1–3/mes**	EUR 3–8/mes	EUR 15–60/mes
Migraciones de esquema	Una sola	Una por inquilino	Una por base
Clientes cómodos	Miles	50–1.000	10–200
Restaurar un cliente solo	Complejo	Posible	Simple
Caso típico	SaaS pyme / herramienta B2B amplia	Mid-market con personalizaciones	Salud, banca, enterprise exigente

Presupuesto de hosting según número de clientes (SaaS de gestión estándar: web + API + PostgreSQL + almacenamiento, con respaldos):

Clientes activos	Infraestructura típica	Costo mensual 2026	% de un ARPU de EUR 80
50	2 instancias + PostgreSQL gestionado 4 GB	EUR 150–300	3,8–7,5%
100	2–3 instancias + PostgreSQL 8 GB con réplica	EUR 250–500	3,1–6,3%
250	balanceador + 3–4 instancias + BD 16 GB + CDN	EUR 500–900	2,5–4,5%
500	Kubernetes gestionado + BD HA 32 GB	EUR 900–1.500	2,3–3,8%
Base por inquilino, 100 clientes	100 bases gestionadas pequeñas	**EUR 1.500–6.000**	**19–75%**

> ***La última fila es la que mata el margen:*** *con base de datos por cliente, la infraestructura se come hasta* ***tres cuartas partes del ingreso****. La base compartida deja el hosting en* ***2,3–7,5% del ARPU****.*

Decisión recomendada: base compartida + `tenant_id` + RLS, con base dedicada vendida como opción Enterprise si algún cliente grande la pide (EUR 300–800 extra/mes). El modelo híbrido solo funciona si el código se diseñó para eso desde el principio.

Consecuencia de ingeniería que no se puede saltar: en base compartida la garantía de que un cliente no ve al otro se apoya en **tres capas** — filtro en la aplicación, políticas RLS de PostgreSQL, y **pruebas automáticas que intentan acceso cruzado en cada despliegue**. Ese paquete (exportación por cliente, borrado al terminar, registro de tratamiento) son **5 a 10 días de desarrollo** que casi nadie cotiza.

---

2. LA PIEZA QUE **NO** SE COMPARTE: EL WHATSAPP

Aquí está el corazón del asunto, y donde el multi-inquilino se vuelve difícil de verdad.

Cada restaurante tiene SU número de WhatsApp. Un número = una sesión. Una sesión, jamás compartida entre inquilinos. Si el número de un restaurante se cae o lo banean, eso **no puede llegarle** al de al lado.

Cómo se aísla de verdad (no basta un `tenant_id`)

Buena práctica	Por qué
Un contenedor por sesión (no por inquilino)	Un inquilino puede tener varias sesiones (ventas, soporte, sedes). Aislar en la frontera de sesión/contenedor hace que la caída de una sesión tenga un radio de daño de exactamente una sesión
Motor ligero, no navegador	Baileys ≈ **50 MB por sesión**; el modelo con navegador (Puppeteer/WEBJS) cuesta ≈ **10× más RAM por número**. Es lo que vuelve económicamente realista alojar muchos clientes
Escala por servidor	WAHA: **hasta ~500 sesiones en un servidor con motor NOWEB**; ~50 con motor WEBJS. Nuestro VPS **ya corre WAHA**
Credenciales por inquilino	Nunca una llave maestra compartida. Una llave por cuenta

Buena práctica	Por qué
Logs y colas por sesión	Un ticket de soporte sobre un cliente no debe obligar a mirar datos de otro

El modelo de datos limpio

`Tenant 1──* Session 1──* Message`
`Tenant 1──* WebhookConfig`

Toda fila con alcance de sesión lleva **dos** identificadores: `session_id` (para aislamiento: colas, límites de ritmo, contenedores) y `tenant_id` (para facturación y propiedad). **Una petición que trae un `session_id` SIEMPRE se valida contra el inquilino autenticado antes de ejecutar nada.** Saltarse esa validación es *la* forma más común de terminar filtrando los datos de un cliente a otro.

Onboarding sin que nosotros toquemos un teléfono

1. Crear la sesión con la llave del inquilino → devuelve un ID antes de que el número esté vinculado.
2. Mostrar el **QR** en la interfaz — el QR **expira y se refresca solo**: la interfaz debe autorefrescarlo, nunca mostrar uno vencido.
3. Esperar/vigilar el estado hasta `connected` y **entonces** encender la función.
4. Manejar la reconexión y la salida: al dar de baja a un inquilino se **borra la sesión por la API** (liberar contenedor y cupo), no basta con desactivar una fila propia.

Honestidad que debe ir en el contrato y en la interfaz: una sesión de WhatsApp que se desloguea a veces exige **escanear el QR otra vez**. Prometer reconexión instantánea garantizada = un ticket de soporte que parece una caída de servicio.

---

3. LO QUE CUESTA DE VERDAD EL CANAL — EL DATO QUE FALTABA

El Radar marcó como riesgo #2 *"los costos y políticas de Meta"*. Ya hay tarifa oficial y publicada, **en vigor desde el 1 de octubre de 2026, y ahora por mensaje** (ya no por conversación; las respuestas de servicio empezaron a cobrarse).

País del cliente	Servicio (respuesta libre)	Plantilla de utilidad	Plantilla de marketing
Colombia	**USD 0,0008**	USD 0,0008	USD 0,0125
Brasil	0,0068	0,0068	0,0625
México	0,0085	0,0085	0,0397
Resto de LatAm (15 mercados)	0,0113	0,0113	0,0740
Chile	0,0200	0,0200	0,0889
Argentina	0,0260	0,0260	0,0618
Perú	0,0300	0,0300	0,0703
Lo que su cliente le escribe a usted	**Gratis**		

Cuatro reglas que cambian la factura: - **Las primeras 1.000 respuestas de servicio de cada mes son gratis**, por número de negocio. No se acumulan y no aplican a plantillas. - **El país del cliente fija el precio**: si el restaurante está en Colombia, aplica la

tarifa de Colombia. - Las respuestas con texto libre dentro de la ventana de 24 h se cobran a tarifa de servicio; una **plantilla** dentro de la ventana se cobra desde la primera. - **Que el cliente escriba primero**: un mensaje de marketing que usted inicia cuesta hasta **15× más** por mensaje según el país.

El mismo trabajo (9.000 respuestas de servicio al mes, con las 1.000 gratis):

País	Costo mensual
Colombia	**USD 6,40**
México	USD 68,00
Resto de LatAm	USD 90,40
Perú	USD 240,00

> ***El mismo volumen cuesta 37,5 veces más en Perú que en Colombia. Conclusión: en Colombia el canal es el más barato de Latinoamérica — prácticamente gratis.*** *El riesgo real no es el costo: es la* ***política*** *(y contra eso, lo que protege es el aislamiento por sesión).*

---

4. UNIT ECONOMICS DE LA PLATAFORMA

Con el precio propuesto en el Radar y la TRM de referencia (USD 1 = **3.164 COP**):

Concepto	Valor
Precio El Cuadre	**$29.900 COP/mes = US$9,45**
Infraestructura por cliente	**US$1–3/mes**
WhatsApp por cliente (hasta ~9.000 respuestas)	**US$0,0064–0,64/mes**
Costo marginal total por cliente	**< US$3,5/mes**
Margen bruto	**> 60%**, incluso alimentando 3 sesiones

Y aquí el hallazgo incómodo. Las plataformas multi-inquilino de restaurantes ya se venden así en el mundo — con bandas de precio explícitas por mercado. Para **Colombia (banda C)** la referencia de venta al público es:

Banda	Por local/mes	Mercados
A · Alto ingreso	US$129 → US$89 por volumen	EE.UU., Canadá, UE-15, Australia, Japón
B · Europa media y Cono Sur	US$71 → US$49	Polonia, Portugal, Grecia, Chile, Uruguay
C · Emergentes grandes	**US$45 → US$31**	India, Brasil, México, **Colombia**, Argentina, Perú
D · ARPU bajo	US$32 → US$22	Filipinas, Indonesia, Vietnam, Egipto, Kenia

> ***US$45 por local/mes ≈ $142.000 COP. Nuestro $29.900 es 1/5 del piso de la banda.*** *O es una* ***cuña deliberada*** *para entrar (defendible: ganar datos y volumen primero), o* ***estamos dejando plata sobre la mesa*** *con el mismo trabajo. Esta*

> *decisión no la tomo yo: es suya, y conviene tomarla **antes** de que el primer cliente vea un precio.*

---

5. LA ARQUITECTURA CONCRETA DE EL CUADRE COMO PLATAFORMA

Dos caras, un solo despliegue:

Cara	Quién entra	Qué ve
Panel del operador	Nosotros	Todos los inquilinos: salud de cada sesión de WhatsApp, uso por mes, cupos, quién está por cortarse, alta/baja de clientes
Panel del dueño	El restaurante	SU día: ventas, gastos, compras, **la utilidad real**, y dónde se le fue la plata
El mensaje nocturno	El dueño, por WhatsApp	*"Hoy vendiste $X. Gastaste $Y. Te quedan $Z de verdad. Aquí se te fue plata: [3 puntos]"*

Todo lo demás ya está construido y es lo que hace que este enfoque nos favorezca:

Activo	Estado	Por qué es decisivo aquí
WAHA + Seawolf Agent	**En producción** (VPS `76.13.109.237`, sesión `seawolf` WORKING)	Ya corremos WhatsApp multi-sesión de verdad. Ningún competidor del radar lo tiene listo
Multi-tenant por chat + **Audit SHA-256** + **RBAC**	Construido	Cada restaurante es un inquilino con rastro auditable: es la respuesta al requisito de aislamiento
El filtro de ruido (CSO)	Construido	**Un dueño de restaurante ES el Cliente Súper Ocupado**
Español nativo · un clic	Construido	El informal no compra software en inglés ni con instalación
Cerradura + dominio propio	`herramientas.sw-st.net`	Canal de demo y venta ya listo

---

6. CÓMO SE VENDE EL ENFOQUE DE "ALBERGAR VARIOS CLIENTES"

Usted intuyó un modelo que tiene nombre y precedente: **programa de socios con marca blanca** (*white-label*).

La división es nítida y está probada: el socio es dueño de **la marca que ve el restaurante, el precio que cobra, la factura, y la relación con el cliente**; el dueño de la plataforma es dueño del **producto, la infraestructura, el aislamiento por inquilino y el soporte de tercer nivel** — y **queda invisible**. Existe un socio que ya corre **100+ apps de restaurante de su propia marca** sobre una sola plataforma.

Dos formas de cobrar (y se pueden combinar): 1. **Directo:** nosotros cobramos al restaurante y listo. 2. **Por socios:** cobramos al socio **por local vivo** al mes, o un **porcentaje del precio que él cobra** — acordado contra su mercado, nunca contra una lista en dólares.

La exclusividad se gana, no se regala (precedente real): ≥10 locales vivos → 12 meses de exclusividad territorial; se mantiene con **+3 locales netos por trimestre y churn ≤10%**; se pierde tras un periodo de gracia de 90 días. Y la protección de prospectos por registro (**90 días, ampliable 30**) es lo que evita que el socio trabaje para que nosotros vendamos en su contra.

Dónde está el apalancamiento en Colombia: los gremios (Acodrés, Asobares) y las agencias/POS locales **ya venden a restaurantes**. El enfoque de albergar varios clientes convierte a cada agencia en un canal, sin contratar un solo vendedor.

---

7. RIESGOS HONESTOS

Riesgo	Severidad	Qué hacer
El informal paga poco (capacidad de pago 3/5 del Radar)	**ALTA**	El multi-inquilino **baja el piso de rentabilidad** (costo marginal < US$3,5), pero **el churn sigue siendo el enemigo real**
Aislamiento mal hecho = un incidente de plataforma, no de un cliente	**ALTA**	Contenedor por sesión + RLS + **pruebas de acceso cruzado en cada despliegue**
Política de Meta: uso no oficial (WAHA) vs API oficial	**ALTA**	Decidir por cliente; el aislamiento por sesión contiene el daño de un baneo
Sobrecosto de desarrollo del multi-inquilino	MEDIA	+15–20% con base compartida. Se paga con creces: evita EUR 82.000/año de infraestructura frente a base por cliente
Migrar después	MEDIA	Mover un cliente grande de base compartida a dedicada: **2–4 semanas** si el código se diseñó para eso. Al revés (fusionar bases) cuesta **2–3× más**
No medimos el uso por inquilino	MEDIA	**Cupos y límites aplicados en el momento de la petición**, no medidos después
Canales de soporte	MEDIA	Un documento de soporte para *"sesión desconectada"*, *"cupo excedido"* y *"webhook que no dispara"* **antes** de vender, y poder apagarle la función a un inquilino **sin desplegar**

---

8. LAS DECISIONES QUE LE PIDO

1. **Modelo de aislamiento:** ¿base compartida + `tenant_id` + RLS, con base dedicada vendida como opción Enterprise? *(recomendado — es el que usan 8 de cada 10 SaaS B2B de este tamaño)*
2. **Canal:** ¿vendemos directo, por socios con marca blanca, o los dos?
3. **Precio:** ¿mantenemos $29.900 como cuña de entrada, o subimos al piso de la banda colombiana (**$142.000**)? Nótese que la banda es el precio de un producto más amplio; aun así, `$29.900` es el 21% de ese piso.
4. **WhatsApp:** ¿WAHA (ya corre, costo ≈ 0, riesgo de política) o API oficial de Meta (US$0,0008/respuesta en Colombia, costos de plantilla, política limpia) **por inquilino**?

---

9. EL PRIMER PASO CONCRETO — COSTO CERO, ESTA SEMANA

El primer entregable del taller sigue siendo **el DEMO en un solo archivo HTML** — pero ahora mostrando **las dos caras** del enfoque que usted intuyó:

```
LADO DUEÑO   → escribe su día (ventas, gastos, compras, merma)
             → recibe EL CUADRE + el mensaje de WhatsApp con sus fugas
LADO PLATAFORMA → una tira con VARIOS restaurantes a la vez
             → la prueba visual de "albergar varios clientes" sin backend
```

Qué prueba: que el dueño *quiere* y *lee* el mensaje (hipótesis 1) **y** que el producto se ve como plataforma, no como app suelta (hipótesis 2). Sin backend, sin llaves, sin servidor.

El Revenue Test sigue intacto y sigue siendo lo que decide: 3 restaurantes, 30 días, reporte nocturno **a mano**, y al día 30 se les pide el dinero. *3 pagan → se construye la plataforma. 0 pagan → se descarta habiendo gastado US$0 en infraestructura.*

Mientras eso corre: usted avanza con LOS SIMPSON en paralelo (`01-LOS-SIMPSON-236GB.txt` , cerrar MiPony primero).

FUENTES

- **WhatsApp Business API — tarifas oficiales LatAm (vigentes 1-oct-2026, por mensaje):** https://contactship.ai/en/blog/whatsapp-business-api-pricing-latin-america-2026
- **Precios WhatsApp Business por país (calculadora, 2026):** https://chatdaddy.tech/es/blog/whatsapp-business-api-pricing-calculator
- **Arquitectura multi-inquilino de WhatsApp para SaaS (aislamiento por sesión/contenedor, modelo de datos, onboarding por QR):** https://simplewa.com/blogs/whatsapp-api-for-saas-platforms
- **Sistema multi-inquilino escalable de WhatsApp API para SaaS (número, llave y enrutamiento por cliente):** https://rapiwa.com/blog/multi-tenant-whatsapp-api-saas-architecture
- **WAHA — escalado: 50 sesiones (WEBJS) o 500 sesiones (NOWEB) por servidor:** https://dev.to/waha/waha-scaling-how-to-handle-500-whatsapp-sessions-3fie · https://github.com/devlikeapro/waha-docs/blob/bf2cb5e1/content/blog/waha-scaling/index.md
- **Aislamiento multi-inquilino en MCP/agentes (patrones pool/bridge/silo):** https://wati.io/en/blog/mcp-multi-tenant-data-isolation
- **Arquitectura y costo de hosting multi-inquilino 2026 (3 modelos, EUR/cliente, sobrecosto 15–30%, caso 300 clientes):** https://kolonell.com/en/blog/multi-tenant-saas-architecture-hosting-cost-2026
- **Plataformas backend SaaS y VPS 2026 (patrón de claves multi-inquilino):** https://techplained.com/top-backend-platforms-saas
- **Programa de socios marca blanca de plataforma de restaurantes (bandas de precio por mercado, exclusividad ganada, división de responsabilidades, caso de 100+ apps de una sola plataforma):** https://supaorder.com/partners
- **Referencia de precios POS Colombia (piso del mercado: $46.000–$139.900 COP/mes):** https://scrampi.com/mejor-pos-restaurantes-colombia · https://menuthere.com/alternatives/toteat
- **TRM de referencia usada:** USD 1 = **3.164 COP** (open.er-api.com, consultada 29-oct-2026 20:04).

DATOS CRUDOS

`C:\Users\Admin\intel\multiinquilino-20261029\` — consultas y fuentes extraídas.

Salve, Gran Monarca. Su intuición tiene nombre propio en la industria (marca blanca multi-inquilino), está probada, y el costo por cliente —lo que siempre mata estos negocios— es el punto más fuerte que tiene el proyecto.

— Bellion, Gran Comandante del Ejército de Sombras.