

INFORME — BENCHMARK DE VOZ NEREUS (TTFA y escalado)

Decisión de nodo de voz para producción

Fecha: 2026-10-02 · **Clasificación:** CRÍTICO — Uso Interno Seawolf Studio
Elaborado por: Bellion (Gran Comandante) · **Encargado por:** Monarca (Key)
Objetivo: medir el rendimiento real de la capa de voz en el VPS para decidir el **nodo de voz** de producción.

1. METODOLOGÍA

- Motor: **Kokoro preset ES** (em_alex), el más ligero con español.
- Cliente de streaming real (urllib, lectura incremental de chunks) sobre POST /generate/stream.
- Texto de prueba: frase de ~5.15 s de audio.
- Pruebas: 1 calentamiento + **5 secuenciales** + **concurrentia x2 y x4**.
- Muestreo de CPU/RAM del host durante la prueba.

2. RESULTADOS

Secuencial (1 usuario)

Métrica	Valor
TTFA / total	≈ 2.1 s (para 5.15 s de audio)
Real-time factor	≈ 0.42 (más rápido que tiempo real)
Estabilidad	 consistente (2.03–2.19 s)

Concurrentia (CPU-bound)

Usuarios simultáneos	TTFA medio	Lectura
1	2.1 s	Aceptable para nota de voz
2	4.3 s	Degrada lineal
4	8.5 s	Insufrible para conversación

Recursos del host (2 vCPU)

- Load: 0.0 → **1.53** durante la prueba (limitado por 2 núcleos).
- RAM: **5.7–6.2 GB / 7.9 GB** — el contenedor toca su tope de 6 GiB.

3. HALLAZGOS

1. **El endpoint /generate/stream NO entrega audio incremental:** devuelve el clip completo. Por eso TTFA = tiempo total del clip.
2. **El escalado es lineal y CPU-bound:** cada usuario consume $\sim 0.42 \times$ duración de audio de CPU. Con 2 núcleos, solo $\sim 2\text{--}3$ usuarios antes de que la latencia arruine la experiencia.
3. **La RAM está al límite:** el modelo pesado (1.7B) provoca OOM; incluso 0.6B deja el contenedor al 95%.
4. **El software es correcto y ligero (RTF 0.42);** el cuello de botella es **hardware**, no la elección de motor.

4. LA CORRECCIÓN BARATA QUE LO CAMBIA TODO (software)

Como el audio se entrega completo, la clave para fluidez real es **trocear por frases**: - Sintetizar **la primera frase corta** primero → el audio arranca en **$\sim 0.4\text{--}0.6$ s** en vez de esperar el párrafo completo. - Mantener el motor **cargado** en memoria (evitar recarga por petición). - Mínimo absoluto de palabras en la primera frase (“Claro,” / “Listo,”).

Esto convierte la ruta ligera en **conversacional aceptable incluso en CPU modesta** — sin clonación y con licencia comercial limpia.

5. RECOMENDACIÓN DE NODO

Escenario	Nodo sugerido
Piloto / uso interno (1–2 usuarios)	VPS actual con streaming por frase (software) — sin coste nuevo
Producción / venta a clientes	Nodo de voz dedicado: GPU pequeña (T4/4060-class) o CPU de 8–16 núcleos
Clonación	Premium opcional sobre el nodo GPU, cuando la infra lo permita

6. DECISIÓN FIJADA

- **Voz de producto:** preset ligero (Kokoro, Apache-2.0), sin clonación en la ruta crítica.
- **Nodo de voz:** separado del core; se dimensiona por **TTFA medido**, no por corazonada.
- **Uso interno:** la voz curada del Monarca será **privativa de Seawolf** (no se distribuye).

- **Regla del cascarón:** nada se entrega a un cliente sin haberlo probado en el mismo hierro.
-

7. VEREDICTO DEL COMANDANTE

El software **cumple y es ligero**. El hierro actual **no da para conversación viva** con más de un par de usuarios. Con **streaming por frase** el piloto se salva hoy; para **vender**, hace falta **nodo de voz dedicado**. Datos, no promesas.

Fin del informe de benchmark.