

INFORME DE EJECUCIÓN — FASE 2 “SEAWOLF NEREUS”

Gateway de modelo: OpenRouter como vía única

Fecha: 2026-10-01 · **Prioridad:** MÁXIMA · **Clasificación:** CRÍTICO — Uso Interno Seawolf Studio **Elaborado por:** Bellion (Gran Comandante) — misión en solitario · **Encargado por:** Monarca (Key) **Objetivo:** enganchar **OpenRouter** como gateway de modelo único, eliminando el coste por token obligatorio atado a proveedores concretos y la resolución dispersa de proveedores. **Resultado:**  **FASE 2 COMPLETADA.** NEREUS genera respuestas con **modelo real** vía **OpenRouter**; el gateway cubre **agente de chat** y **task worker**; suite en **276/276** verdes.

1. RECONOCIMIENTO — DÓNDE SE RESOLVÍA EL MODELO

- Punto **único** de resolución: `apps/server/src/engine/tanstack-agent.ts` → función `adapter(spec)`, que traduce "proveedor/modelo" a un adaptador del SDK. Solo soportaba `openai`, `anthropic` y `google`.
 - Tanto el **agente de chat** (`conversation.ts`) como el **task worker** (`engine/model.ts:296`) llaman al **mismo** `tanstackAgent(...)` → `adapter(...)`. **Una sola puerta que cambiar.**
 - Formato previo: `MODEL=<proveedor>/<modelo>` con `OPENAI_BASE_URL`, `ANTHROPIC_BASE_URL`, `GOOGLE_GENERATIVE_AI_BASE_URL`.
-

2. LO QUE SE CONSTRUYÓ

2.1 Proveedor openrouter de primera clase

En `engine/tanstack-agent.ts`, usando el adaptador `openaiCompatibleText` (subruta `@tanstack/ai-openai/compatible`, hecha para endpoints compatibles con OpenAI):

- **Formato de spec:** `openrouter/<vendor>/<model>` — p. ej. `openrouter/anthropic/claude-sonnet-4.5` (el id de OpenRouter conserva su prefijo de vendor).
- **Base URL:** `OPENROUTER_BASE_URL` o por defecto `https://openrouter.ai/api/v1`.
- **Clave:** `OPENROUTER_API_KEY`.
- **Protocolo:** `chat-completions` (el que habla OpenRouter).

- **Cabeceras de identificación:** HTTP-Referer y X-Title (atribución en OpenRouter) configurables.
- **Reintentos:** hereda MODEL_MAX_RETRIES.

2.2 Configuración

- `agent.ts` → `agentConfigured()` ahora reconoce `OPENROUTER_API_KEY` como clave válida.
- `.env` de NEREUS: `AGENT_BACKEND=model`, `MODEL=openrouter/openai/gpt-4o-mini`, `OPENROUTER_API_KEY=<clave del Monarca>`, `OPENROUTER_REFERER`, `OPENROUTER_TITLE`. (La clave se reutiliza del propio `/root/.hermes/.env` del VPS; **no se expone** en informes ni logs.)

3. VERIFICACIÓN REAL

Prueba	Resultado
<code>pnpm typecheck + lint + build:server</code>	✅ limpios
Suite completa	✅ 276/276 · 0 fallos
Validez de la clave OpenRouter (<code>/api/v1/models</code>)	✅ 462 modelos disponibles
Run con modelo REAL vía OpenRouter (gpt-4o-mini)	✅ stream RUN_STARTED→TEXT_MESSAGE_CONTENT(15)→RUN_FINISHED, sin RUN_ERROR
Tool-calling vía OpenRouter	✅ el modelo invocó herramientas (<code>write_computer_file</code> , <code>start_computer</code>) y recibió resultados
Persistencia tras el run	✅ fila en Postgres: 206 eventos · 5 mensajes
Fuente de la clave	✅ reutilizada del VPS, no expuesta

Nota de honestidad: una primera prueba con un **modelo gratuito** (`qwen3.8-27b:free`) devolvió `400 Provider returned error` (límite del plan gratuito). El gateway funcionó (transmitió respuesta real en español), pero **el proveedor gratis era inestable**. Se fijó por defecto un modelo **pago barato** (`openai/gpt-4o-mini`) que corrió **limpio**. Saldo OpenRouter del Monarca: **~\$19.33 disponibles**.

4. ARCHIVOS MODIFICADOS

Archivo	Cambio
<code>apps/server/src/engine/tanstack-agent.ts</code>	caso openrouter vía <code>openaiCompatibleText</code> + import
<code>apps/server/src/agent.ts</code>	<code>agentConfigured</code> acepta <code>OPENROUTER_API_KEY</code>

5. LÍMITES HONESTOS

1. **Modelo por defecto:** openrouter/openai/gpt-4o-mini (pago, baratísimo). Cambiarlo es **una línea** en .env (MODEL=openrouter/...). Los modelos :free existen pero son inestables.
 2. **Computadora Docker** no habilitada → si el modelo intenta usarla, recibe “Computer is not configured” (comportamiento esperado, no fallo del gateway).
 3. **Voz y avatar** aún no existen (Fases 3 y 8 del roadmap).
 4. El proceso se levanta a mano en pruebas (systemd pendiente).
-

6. ESTADO Y PENDIENTES

-  **Fase 0** — clone + build (276 tests).
 -  **Fase 1** — persistencia propia; servicio cerrado arrancado.
 -  **Fase 2** — **gateway OpenRouter** operativo con modelo real.
 -  **Fase 3** — Voz: **VoiceBox (TTS/STT/persona) + Pipecat (barge-in)**.
 -  Endurecer operación (systemd) + rotación de credenciales.
 -  Reporte para auditoría de **Beru**.
-

7. VEREDICTO DEL COMANDANTE

NEREUS **piensa**. Ya no hay que pelear con proveedores dispersos ni con la clave cerrada: **una sola puerta (OpenRouter)** sirve al chat y a las tareas. El camino queda allanado para la voz. Cadencia sostenida: **tres fases en dos jornadas**.

| **Recomendación:** autorizar **Fase 3 — Voz (VoiceBox + Pipecat)**.

Fin del informe de Fase 2. Listo para auditoría de Beru.