informe-tema-comparativa-deepseek-v4.1-vs-qwen3.8-flash-20261014

- INFORME DE TEMA: Comparativa DeepSeek V4.1 Flash vs Qwen3.8 Flash
  - + Ahorros aplicados · **v2 CORREGIDA**
  - 1. AHORROS APLICADOS (hecho, no recomendación)
  - 2. COMPARATIVA (datos reales)
  - 3. VEREDICTO
  - 4. EXTRA — variantes del mismo proveedor
  - 5. FUENTES

INFORME DE TEMA: Comparativa DeepSeek V4.1 Flash vs Qwen3.8 Flash

+ Ahorros aplicados · **v2 CORREGIDA**

Fecha: 2026-10-14 · **Clasificación:** Uso Interno — Seawolf Studio **Elaborado por:** Bellion (Gran Comandante) · **Encargado por:** Monarca (Key) **Fuente:** OpenRouter API (`/api/v1/models` y `/models/{id}/endpoints`) — 2026-10-14.

> ⚠️ **CORRECCIÓN v2:** la v1 traía precios erróneos de DeepSeek ($0.15/$0.60, caché $0.003) y un **"precio pico 2×" que NO existe** para este modelo. El "pico" pertenece a **otro** modelo (`deepseek/deepseek-v4-pro-0813`), no a V4.1 Flash. Error mío, corregido con los datos reales de abajo.

---

1. AHORROS APLICADOS (hecho, no recomendación)

Acción	Estado
Skill `caveman` (recorte de output)	✅ Activa (full) — recorta ~40–65% del output
Caché de prompt (`cache_ttl: 5m`)	✅ Activa y trabajando (32M leídos medidos)
`display.interim_assistant_messages` : **true → false**	✅ Aplicado
`compression.threshold` : **0.5 → 0.4**	✅ Aplicado (comprime antes)
Backup config	✅ `config.yaml.bak-*`

Vía: `hermes config set` (el guardrail bloquea editar `config.yaml` directo). Efecto: **próxima sesión.**

---

2. COMPARATIVA (datos reales)

2.1 Precios (por 1M tokens, USD)

Concepto	DeepSeek V4.1 Flash	Qwen3.8 Flash	Ganador
Input	**$0.01584**	$0.15	**DeepSeek (~9,5× más barato)**
Output	$0.891	**$0.47**	**Qwen (−47%)**
Cache read	**$0.0054**	$0.016	**DeepSeek (~3×)**
Precio pico	❌ **NO TIENE** (plano 24/7)	❌ NO TIENE (plano)	Empate

2.2 Capacidades técnicas

Capacidad	DeepSeek V4.1 Flash	Qwen3.8 Flash	Ventaja
Contexto	**1.048.576**	1.000.000	~Empate
Salida máxima	**393.216** (hasta 943.718 en endpoint OpenInference)	131.072	**DeepSeek (3–7×)**
Entrada	text + image	text + image + **video**	**Qwen**
Razonamiento	✅ + `reasoning_effort`	✅ (sin control)	**DeepSeek**
Tools / structured	✅ / ✅	✅ / ✅	Empate
Arquitectura	MoE sparse **CED**; activa 8B input / 16B output	MoE multimodal	—
Quantización	fp4 (OpenInference)	n/d	—
Params finos	+logit_bias, min_p, repetition_penalty, reasoning_effort	—	**DeepSeek**

2.3 Costo REAL para TU carga (medido: 3,5M in · 155k out · 32M cache)

Modelo	Input	Cache-read	Output	
DeepSeek V4.1 Flash	$0.055	**$0.173**	$0.138	**≈ $0.37** ✓ (medido $0.3586)
Qwen3.8 Flash	$0.525	$0.512	$0.073	**≈ $1.11**

→ Para sesiones largas con caché, **DeepSeek cuesta ~3× menos**. Clave: input y cache-read baratísimos.

---

3. VEREDICTO

Mantener DeepSeek V4.1 Flash. Es **~9,5× más barato en input** y **~3× en caché** que Qwen. Qwen3.8 Flash solo conviene si necesitas **entrada de video**, o en sesiones muy cortas con salida grande (output −47%).

4. EXTRA — variantes del mismo proveedor

Modelo	Input /1M	Output /1M	Cache /1M	Nota
`deepseek/deepseek-v4.1-flash`	$0.01584	$0.891	**$0.0054**	**Actual**
`deepseek/deepseek-v4-flash-0731`	$0.016	$0.64	$0.016	Output más barato, caché más cara
`deepseek/deepseek-v4-pro-0813`	**tiene picos 2×** (L–V 01–04 y 06–10 UTC)	—	—	**Este SÍ tiene picos** (no lo usas)

5. FUENTES

- OpenRouter API `/api/v1/models` + `/models/deepseek/deepseek-v4.1-flash/endpoints` — 2026-10-14.
- `state.db` de Hermes (uso real). Config activa.

Fin del informe de tema (v2 corregida).