

INFORME — GRAPHITI CABLEADO + AUDITORÍA DE MODELOS (coste)

Memoria temporal integrada y coste de IA reducido a casi cero

Fecha: 2026-10-02 · Clasificación: CRÍTICO — Uso Interno Seawolf Studio
Elaborado por: Bellion (Gran Comandante) · Encargado por: Monarca (Key)

1. GRAPHITI → NEREUS (memoria temporal) — INTEGRADO Y VERIFICADO

Pieza	Cambio
apps/server/src/temporal.ts	NUEVO — cliente MCP (Graphiti): addEpisode + searchFacts, con sesión y best-effort
engine/conversation.ts	remember_fact → añade episodio temporal
engine/routes.ts	POST /memories → añade episodio temporal
engine/model.ts	Los hechos temporales entran al contexto de tareas (temporalFacts)
.env	GRAPHITI_MCP_URL

Verificación real: memoria creada por NEREUS → episodio presente en el grafo (grupo local-user, con fecha) vía get_episodes. typecheck + build  · servicio active.

2. AUDITORÍA DE MODELOS (anti-gasto)

Precios reales (OpenRouter, USD por 1M tokens)

Modelo	Tools	Entrada	Salida
nvidia/nemotron-3-super-120b-a12b:free		0	0
qwen/qwen3.8-27b:free		0	0
deepseek/deepseek-v4-flash		0,028	0,056
deepseek/deepseek-v4.1-flash		0,020	0,600

Modelo	Tools	Entrada	Salida
deepseek/deepseek-v4.1-flash:batch	✓	0,112	0,336
ibm-granite/granite-4.0-h-micro	✗	0,017	0,112

⚠ Hallazgo sobre el :batch

Los modelos :batch son **asíncronos** (procesan por lotes con retraso) → **NO sirven para chat en vivo**; solo para trabajos de fondo. Además, en este caso su **entrada es más cara** que la versión en vivo.

Cambios aplicados

Servicio	Antes	Ahora	Coste
NEREUS (chat)	openai/gpt-4o-mini	nvidia/nemotron-3-super-120b-a12b:free	Gratis
Mem0 (extracción)	openai/gpt-4o-mini	deepseek/deepseek-v4-flash	~0,03/1M
Graphiti (extracción)	openai/gpt-4o-mini	deepseek/deepseek-v4-flash	~0,03/1M
Embeddings	text-embedding-3-small	(igual)	muy bajo

Fallback documentado en .env: openrouter/deepseek/deepseek-v4-flash si el gratis da límite.

3. VERIFICACIÓN TRAS EL CAMBIO

- **Mem0** con modelo barato: alta correcta (ADD).
- **NEREUS chat** con modelo **gratis**: respuesta real “*Sí, estoy funcionando con el modelo gratuito.*” en **7 s, sin errores ni 429**.
- Servicios: nereus-api activo, Mem0 y Graphiti arriba.

4. ESTADO

-  **Fase 4 completa**: Mem0 (semántica) + Graphiti (temporal) integrados en el agente y probados.
-  Coste de IA del sistema reducido a **gratis / casi gratis**.
-  systemd para los servicios nuevos (Mem0, Graphiti) — pendiente.
-  Pruebas integrales.

5. VEREDICTO DEL COMANDANTE

NEREUS recuerda por significado y en el tiempo, y ya **no sangra créditos**: chat gratis, fondo a céntimos. Blindado el bolsillo del Monarca y avanzada la memoria al completo.

Fin del informe.