

INFORME — STREAMING POR FRASES EN NEREUS (implementación)

La ruta ligera ya da conversación fluida en el VPS actual

Fecha: 2026-10-02 · Clasificación: CRÍTICO — Uso Interno Seawolf Studio
Elaborado por: Bellion (Gran Comandante) · Encargado por: Monarca (Key)

1. QUÉ SE IMPLEMENTÓ

voice-gateway.py — pasarela de voz que trocea la respuesta en **frases** y entrega el audio de cada una **en cuanto está lista**, en vez de esperar al párrafo completo. - Entrada: POST /speak {text, profile_id?, engine?}. - Salida: flujo [uint32 BE largo][WAV] por frase (una tras otra, con flush). - Motor: VoiceBox local (Kokoro ES), **sin clonación**, Apache-2.0. - Enrutado: GET /health.

2. RESULTADOS MEDIDOS (VPS 2 vCPU, sin GPU)

Métrica	Baseline (párrafo entero)	Gateway por frases
TTFA (inicio de audio)	6.17 s	0.75 s
Total de audio	6.17 s	6.87 s
Entrega	Bloque único al final	5 frases en flujo
Mejora percibida	—	≈ 8× menos espera

- El **total** sube ligeramente (coste por frase), pero lo que **oye el usuario** aparece **8 veces antes**.
- Consistente entre intentos (TTFA 0.70–0.78 s).

3. POR QUÉ IMPORTA

- Confirma que **el software ligero es conversacional** en hardware modesto: la espera está en **0.75 s** (umbral aceptable).
- **No requiere GPU ni clonación** para el producto base → **licencia limpia y coste bajo**.
- La clonación (mi voz / la del Monarca) queda como **premium opcional** cuando la infraestructura lo permita.

4. PITFALL CORREGIDO

El primer framing (HTTP chunked + longitud interna) desincronizaba al cliente → audio corrupto. Se migró a **framing binario simple** (Connection: close, longitud explícita por frase) → entrega **verificada íntegra** (661 KB, 5 frases).

5. ESTADO

-  Pasarela de voz operativa en el VPS (127.0.0.1:8799).
-  TTFA conversacional demostrado (0.75 s) sin GPU.
-  Integrar la pasarela al flujo de NEREUS (que el agente hable por ella).
-  Decide nodo de voz para venta (GPU o CPU multinúcleo).
-  Persistencia/servicio (systemd) y exposición segura.

6. VEREDICTO DEL COMANDANTE

La espera se mató con ingeniería, no con dinero. El pilar de voz del producto **ya funciona en el VPS actual**. El premium de clonación espera a la infraestructura, como se decidió. Avanzamos con base sólida.

Fin del informe de streaming por frases.