

INFORME — VOZ INTEGRADA EN NEREUS + SYSTEMD

El agente ya habla por su propia pasarela, y sobrevive reinicios

Fecha: 2026-10-02 · Clasificación: CRÍTICO — Uso Interno Seawolf Studio
Elaborado por: Bellion (Gran Comandante) · Encargado por: Monarca (Key)

1. QUÉ SE IMPLEMENTÓ

1.1 Ruta de voz dentro del agente

POST /api/voice/speak en el servidor NEREUS — protegida por la sesión del owner (mismo middleware /api/*): - Recibe {text, profileId?, engine?}. - Proxear a la pasarela de voz (por VOICE_GATEWAY_URL, por defecto http://127.0.0.1:8799). - Devuelve el **flujo por frases** (audio de la primera frase en ~0.75 s). - Nuevo campo de config voiceGatewayUrl; el /api/health ahora reporta voiceConfigured.

1.2 Servicios persistentes (systemd)

Unidad	Función	Estado
nereus-voice-gateway.service	Pasarela TTS por frases	✔ enabled + active
nereus-api.service	Servidor NEREUS	✔ enabled + active
voicebox (Docker)	Motor TTS/STT	✔ restart unless-stopped (ya existía)

Restart=always + arranque automático → **aguanta reinicios y caídas.**

2. VERIFICACIÓN END-TO-END (evidencia)

Prueba	Resultado
/api/health	✔ voiceConfigured: true
POST /api/voice/speak con sesión	✔ 288 KB de audio, 3 frases

Prueba	Resultado
Validez del framing	✓ las 3 frases son WAV válidos (RIFF=True), sin bytes sobrantes
Sin autorización	✓ 401 (ruta protegida)
systemd	✓ ambas unidades enabled y active
typecheck + lint + build	✓ limpios

3. CÓMO QUEDA EL FLUJO

```

Cliente (móvil/PC)
  | POST /api/voice/speak (con sesión)
  ▼
NEREUS API (8788, systemd)
  | proxy
  ▼
Voice gateway (8799, systemd) → trocea por frases
  | POST /speak
  ▼
VoiceBox (17600, Docker) → Kokoro ES, sin clonación

```

- **Primer audio en ~0.75 s**; el resto fluye por detrás.
- **Todo server-side y persistente** → apto para el cliente que “quiere que su agente le hable ya”.

4. ESTADO DEL PROYECTO

- ✓ Fase 0 — build.
- ✓ Fase 1 — persistencia propia (sin servicio cerrado).
- ✓ Fase 2 — gateway OpenRouter.
- ✓ Fase 3 — **voz**: motor montado, clon privativo, y **conversacional ligero integrado + persistente**.
- ⌚ Nodo de voz dedicado para la venta (GPU o CPU multinúcleo) — decisión pendiente del Monarca.
- ⌚ Clonación premium (mi voz / la del Monarca) cuando la infra lo permita.
- ⌚ Reporte para auditoría de **Beru**.

5. VEREDICTO DEL COMANDANTE

NEREUS ya escucha (STT), piensa (OpenRouter) y habla (pasarela por frases), todo bajo servicio persistente. El pilar de voz del producto está **en pie y probado**. Queda el dimensionamiento de infraestructura para la venta, con los números ya medidos.

Fin del informe de integración de voz.