

SEAWOLF NEREUS — Plan Maestro v2 (Seawolf Studio)

- PLAN MAESTRO v2 — “SEAWOLF NEREUS”
 - Decisiones técnicas críticas: Memoria · Voz · Continuidad multiplataforma
 - 0. AJUSTES AL ROADMAP (orden del Monarca)
 - 1. DECISIÓN 1 — LA MEJOR MEMORIA PARA NEREUS
 - 2. DECISIÓN 2 — VOZ: ¿SIRVE “VOICEBOX”?
 - 3. DECISIÓN 3 — CONTINUIDAD MULTIPLATAFORMA (PC ↔ Móvil)
 - 4. ROADMAP v2 (actualizado)
 - 5. COMPONENTES FINALES (todo verificado, licencia permisiva)
 - 6. SIGUIENTE PASO

PLAN MAESTRO v2 — “SEAWOLF NEREUS”

Decisiones técnicas críticas: Memoria · Voz · Continuidad multiplataforma

Fecha: 2026-09-30 · **Prioridad:** MÁXIMA · **Clasificación:** CRÍTICO — Uso Interno Seawolf Studio **Elaborado por:** Bellion (Gran Comandante) — misión en solitario · **Encargado por:** Monarca (Key) **Base:** CopilotKit/openmuse (MIT) · Todas las piezas verificadas contra GitHub API el 2026-09-30.

0. AJUSTES AL ROADMAP (orden del Monarca)

Antes (v1)	Ahora (v2)	Motivo
OmniRoute como gateway	OpenRouter (único gateway, pago por uso)	OmniRoute falla en rotación de modelos; el Monarca prioriza fiabilidad
Memoria = “mem0 (?)”	DECISIÓN TOMADA (§1)	—
Voz genérica	VoiceBox + capa de diálogo (§2)	—
Continuidad multiplataforma sin definir	Arquitectura definida (§3)	—

1. DECISIÓN 1 — LA MEJOR MEMORIA PARA NEREUS

Veredicto: Mem0 como capa principal + Graphiti como capa temporal

Por qué Mem0 es la elección principal: - **Apache-2.0, self-hosteable** (66.4k★) — cumple el criterio Seawolf de licencia permisiva y 100% privado. - **Es la capa de memoria, no un runtime** — se acopla a NUESTRO agente sin reemplazarlo (Letta sí lo reemplazaría: es una plataforma completa). - **Diseñada para**

personalización y continuidad entre sesiones — exactamente lo que un agente personal necesita. - **Latencia baja y ahorro de tokens** (~6.900 tokens/recuperación vs 25.000+ del contexto completo). - **Adopción de mercado real:** es la capa de memoria que usa el Agent SDK de AWS.

Por qué añadir Graphiti (Zep) como capa temporal: - **Apache-2.0** (31.3k★) — grafo de conocimiento **temporal:** cada hecho lleva ventana de validez. Los hechos contradichos se **invalidan, no se borran**. - Crítico para un agente de confianza: que **no actúe sobre un dato obsoleto** (“el Monarca dijo X en marzo, pero Y en septiembre”). Es la memoria “auditable”.

⚠ Honestidad brutal (obligatoria): los benchmarks de memoria están disputados

Los números que circulan son **auto-reportados por los vendedores**. Un informe **independiente** midió Mem0 en **49.0 sobre LongMemEval**, contra el **94.4 auto-reportado**. Zep rebajó su propio score de LoCoMo de 84% a 75.14%, y Mem0 lo reprodujo en 58.44%. **Conclusión: no elegimos por el número de marketing, elegimos por arquitectura y encaje.** Y mediremos con nuestros propios datos (evals internas) antes de confiar.

Alternativas evaluadas (descartadas para primaria)

Opción	Lic.	Por qué NO como primaria
Letta (25k★)	Apache-2.0	Es un runtime completo ; adoptarlo para memoria = “comprar un SO por su sistema de archivos”. Lock-in.
Zep (servidor)	—	El servidor legacy ya no se desarrolla ; solo Graphiti (el motor) sigue vivo.
cognee (31.2k★)	Apache-2.0	Buen auto-mejora desde correcciones; menos maduro para personalización general.
Supermemory (31k★)	MIT	Candidato sólido y totalmente local ; guardar como plan B si queremos cero dependencia.

Matriz final de memoria: Mem0 (principal, personalización) + Graphiti (temporal/auditoría). Interfaz propia y **sustituible** (no nos casamos con ninguno).

2. DECISIÓN 2 — VOZ: ¿SIRVE “VOICEBOX”?

Sí, pero para la MITAD del problema. Verificado: `jamiepine/voicebox` — **56.061★, MIT** — “el estudio de voz open source: clona, dicta, crea”. Local-first, 23 idiomas, 7 motores TTS (incl. Kokoro, Chatterbox), STT con Whisper.

✓ Lo que VoiceBox Sí cubre

Capacidad	Detalle
TTS con clonación de voz	Clona desde segundos de audio; +50 voces preset
Personalidad de voz (¡clave para ti!)	Permite atachar una persona libre a cada perfil de voz — la voz de NEREUS con su carácter
STT / dictado	Whisper integrado, hotkey global, push-to-talk y toggle
Multilinguaje	23 idiomas — español nativo
Integración con agentes vía MCP	Una llamada de herramienta (<code>voicebox.speak</code>) y tu agente habla con la voz que clonaste
Privacidad total	Modelos y datos nunca salen de la máquina — alineado con Seawolf
Expresividad	Tags paralingüísticos (<code>[laugh]</code> , <code>[sigh]</code>) con Chatterbox Turbo

✗ Lo que VoiceBox NO cubre

No es un **framework de diálogo en tiempo real**. Es un **estudio de voz (I/O)**: hacer TTS/STT. **No gestiona turnos ni barge-in** por sí solo (su lógica es dictado/push-to-talk, no conversación full-duplex). La interrupción (“hablo y se calla”) es una **capa de ingeniería aparte**.

La pieza que falta: interrupción (barge-in) — verificado

Herramienta	★	Lic.	Qué aporta
Kyutai Moshi	11.2k	Apache-2.0	Full-duplex nativo — el mejor para interrupciones reales; speech-to-speech en tiempo real (~200 ms)
Pipecat	16.1k	BSD-2	Framework de orquestación de voz: VAD, turn-taking, barge-in ; conecta cualquier STT+LLM+TTS
LiveKit Agents	14.4k	Apache-2.0	Producción; maneja interrupciones, RTC a escala
Ultravox	4.6k	MIT	LLM multimodal rápido para voz en tiempo real
Kyutai DSM	3.0k	Apache-2.0	STT/TTS streaming de Kyutai

🎯 Stack de voz recomendado para NEREUS

```
Micrófono → STT (Whisper, dentro de VoiceBox)
  → Orquestación de turnos + barge-in (Pipecat — o LiveKit Agents)
  → LLM (OpenRouter)
  → TTS (VoiceBox: voz clonada + persona)
  → Altavoz
```

Resumen: VoiceBox = la voz (salida/entrada + clonación + persona). Pipecat (o LiveKit) = el cerebro conversacional que permite interrumpir. Juntos dan fluidez, velocidad y barge-in. Si buscamos la interrupción más natural posible (hablar y que se calle al instante), **Moshi** es la referencia — pero acopla el diálogo a su propio modelo; Pipecat mantiene nuestra lógica y herramientas.

3. DECISIÓN 3 — CONTINUIDAD MULTIPLATAFORMA (PC ↔ Móvil)

Requisito: empezar en PC, salir, y seguir desde el móvil con el progreso intacto.

Arquitectura: estado autoritativo en servidor + canal en tiempo real + caché local

El núcleo ya nos lo da el original: las **tareas durables viven en el servidor** (no en el cliente). El progreso de un agente que “sigue trabajando” es **intrínsecamente server-side**. Solo hay que exponerlo a todos los dispositivos.



Componentes verificados para la capa de sync: | Necesidad | Opción | Lic. | Nota | |———|———|———|
———| | Canal en tiempo real (progreso en vivo) | **SSE / WebSocket propio** o **Supabase Realtime** | Apache-2.0 | El original ya usa SSE/AG-UI | | Estado local-first (seguir offline) | **ElectricSQL** (10.4k★) o **PowerSync** | Apache-2.0 | Sincroniza Postgres ↔ cliente | | Estado colaborativo/CRDT (si hiciera falta) | **Automerger** (6.6k★) / **Yjs** | MIT | Para edición concurrente | | **✗** Descartado | **Triplit** | **AGPL-3.0** | Copyleft — fuera |

Decisión: servidor autoritativo (Postgres) + SSE/WebSocket para vivo + ElectricSQL/PowerSync para caché offline. Así: abres en PC → el trabajo corre en el servidor → abres el móvil → **la misma sesión, el mismo progreso, en vivo**. Sin lógica de sync frágil.

4. ROADMAP v2 (actualizado)

Fase	Entregable	Cambios v2
0	Clone + build local del original	igual
1	Persistencia propia (adiós servicio cerrado)	Postgres + pgvector
2	Modelo: OpenRouter (reemplaza OmniRoute)	CAMBIO
3	Voz: VoiceBox (TTS/STT/persona) + Pipecat (barge-in)	DEFINIDO
4	Memoria: Mem0 + Graphiti	DEFINIDO
5	Conectores Composio (ya instalado + Gmail OAuth)	igual
6	OCR (Unstructured) + Push	igual
7	Continuidad multiplataforma (SSE + ElectricSQL/PowerSync)	DEFINIDO
8	Multi-tenant + marca Seawolf + despliegue	igual

Estimación: 4-6 semanas de ingeniería. Con 3 decisiones cerradas hoy, el camino se acorta y se desriesga.

5. COMPONENTES FINALES (todo verificado, licencia permisiva)

Capa	Componente	Lic.	★
Base del agente	CopilotKit/openmuse	MIT	3.4k
UI/streaming	CopilotKit + AG-UI	MIT	37.6k
Gateway de modelo	OpenRouter	(servicio)	—
Memoria principal	Mem0	Apache-2.0	66.4k
Memoria temporal	Graphiti	Apache-2.0	31.3k
Voz — TTS/STT/persona	VoiceBox	MIT	56.1k
Voz — diálogo/berge-in	Pipecat (o LiveKit Agents)	BSD-2	16.1k
Full-duplex (opción)	Kyutai Moshi	Apache-2.0	11.2k
Conectores	Composio	MIT	30.4k
Docs/OCR	Unstructured	Apache-2.0	15.5k
Sync multiplataforma	ElectricSQL / PowerSync	Apache-2.0	10.4k / 0.7k
Vector DB	pgvector / Qdrant	PostgreSQL / Apache-2.0	23.2k / 34.9k
Navegador	Playwright	Apache-2.0	96.9k
Móvil/Web	Expo	MIT	52.5k

Cero copyleft. Cero servicio cerrado obligatorio. Todo auto-hospedable.

6. SIGUIENTE PASO

Plan v2 con las 3 decisiones críticas cerradas. **Autoriza la Fase 0** (clone + build local del original en el VPS) para convertir el plan en código ejecutable — la cancha es mía, pero la orden de arranque es tuya.

Fin del informe v2. Listo para auditoría de Beru.